

Biztonságkritikus közlekedési táblák detektálása és robusztussági vizsgálata

1. Célkitűzés

A projekt célja egy olyan képfeldolgozó és mélytanulás alapú rendszer fejlesztése, amely képes közúti környezetben rögzített képeken automatikusan detektálni és azonosítani bizonyos biztonságkritikus közlekedési táblákat. A vizsgált kategóriák: STOP tábla, gyalogátkelőhely, sebességkorlátozó tábla, behajtani tilos, valamint elsőbbségadás kötelező.

A rendszer központi eleme egy modern, egyfázisú objektumdetektáló hálózat (YOLO-család), amely a táblák helyét és típusát egy lépésben becsüli. A cél nemcsak a detektálás pontosságának maximalizálása, hanem annak vizsgálata is, hogy különböző képi torzítások (zaj, elmosódás, fényviszonyok változása) milyen hatással vannak a teljesítményre. Ennek érdekében robusztussági elemzést végzünk a megadott adatbázison.

2. Létező megoldások – state-of-the-art áttekintés

A közlekedési táblák felismerésének korai megközelítései klasszikus képfeldolgozási módszereken alapultak, például HSV színtérben végzett szegmentáción, küszöbölésen és Hough-transzformáción, amelyekkel kör, háromszög vagy nyolcszög alakú táblák voltak detektálhatók. Bár ezek a módszerek számításigényben kedvezőek, erősen érzékenyek a megvilágítás változásaira, árnyékokra, részleges takarásra és háttérzajra, ami korlátozza alkalmazhatóságukat valós közúti környezetben.

A modern rendszerek mély neurális hálókat alkalmaznak, amelyek jelentősen felülmúlják a klasszikus megoldásokat pontosság és robusztusság tekintetében. A German Traffic Sign Recognition Benchmark (GTSRB) és a German Traffic Sign Detection Benchmark (GTSDB) váltak a terület standard adatbázisaivá [6]. A GTSRB-n elért korai áttörést Cireşan és munkatársai érték el többoszlopos mély CNN-architektúrájukkal, amely akkoriban rekordpontosságot produkált [2].

Objektumdetektálás terén a kétfázisú detektorok, például a Faster R-CNN [5], régiójavaslatokra építve érnek el magas pontosságot, azonban számításigényük miatt kevésbé alkalmasak valós idejű alkalmazásokhoz. Az egyfázisú detektorok, mint az SSD (Single

Shot MultiBox Detector) [3] és a YOLO (You Only Look Once) család [4], a teljes képet egy lépésben dolgozzák fel, így lényegesen gyorsabbak. A YOLO újabb generációi (YOLOv5, YOLOv7, YOLOv8) kiváló kompromisszumot kínálnak sebesség és pontosság között, ezért széles körben alkalmazzák közlekedési jelenetekben és beágyazott rendszerekben.

A legújabb kutatási irányt a transzformer-alapú detektorok képviselik, például a DETR (Detection Transformer) [1], amely end-to-end módon, régiójavaslatok nélkül oldja meg a detektálást. Bár ezek a modellek ígéretesek, tipikusan nagyobb számítási kapacitást igényelnek, ezért jelen projektben a YOLO-alapú megoldás bizonyul a legpraktikusabbnak, mivel jól illeszkedik a valós idejű, beágyazható, közlekedési környezetben működő rendszerek követelményeihez.

3. Megvalósítás lépései

WP1 – Tervezés és irodalomkutatás (1 hét)

- Kapcsolódó cikkek, benchmarkok (GTSRB, GTSDb, YOLO-alapú megoldások) áttekintése.
- A kiválasztott YOLO-variáns (pl. YOLOv5/YOLOv8) és keretrendszer (PyTorch) meghatározása.
- Rendszerarchitektúra megtervezése: adatbetöltés, annotációk kezelése, tanítási pipeline, kiértékelés, robusztussági modul.

WP2 – Adatfeldolgozás és előkészítés (2 hét)

- A megadott adatbázis betöltése (közúti képek és címkék: táblák elhelyezkedése és típusa).
- Annotációk konvertálása YOLO-formátumba.
- Train/validation/test felosztás, osztály-eloszlás vizsgálata.
- Alapvető adataugmentációk beállítása.

WP3 – YOLO-alapú detektáló modell implementálása és tanítása (3 hét)

- A YOLO-architektúra konfigurálása (input méret, backbone, hyperparaméterek).
- Modell tanítása, tanulási görbék monitorozása.
- Kiértékelés: mAP, precision–recall görbék, osztályonkénti teljesítmény.

- Vizualizáció: detektált táblák megjelenítése.

WP4 – Robusztussági vizsgálat (2 hét)

- Torzított teszhalmazok generálása:
 - Gauss-elmosódás,
 - Fényerő, kontraszt, gamma módosítása,
 - Részleges takarás szintetikus beillesztése.
- Teljesítmény mérése bizonyos torzítási szinteken.
- Robusztussági görbék készítése (pl. zajszint vs. mAP).


WP5 – Dokumentáció és prezentáció (2 hét)

- Eredmények összegzése, riport készítése.
- Grafikonok, vizualizációk, robusztussági elemzés bemutatása.
- Jövőbeli bővítési lehetőségek áttekintése.

WP6 – Konzultáció és finomítás (2 hét)

- Konzultáció az oktatókkal.
- A modell és az eredmények finomítása.

Időterv (Gantt diagram)



4. Eredmények dokumentálása

Az eredmények kiértékelése többféle módon történik:

- mAP (mean Average Precision) és osztályonkénti precision/recall,
- Konfúziós mátrix,
- Robusztussági grafikonok (zaj, elmosódás, fényerő vs. mAP),
- Vizualizációk különböző torzítási szinteken,
- Tanulási görbék (loss, mAP epochonként).

5. Skálázhatóság és beágyazhatóság

A rendszer moduláris felépítésű: az adatfeldolgozó pipeline, a detektáló modell és a robusztussági modul egymástól jól elválasztható. Ez lehetővé teszi:

- Új táblatípusok egyszerű hozzáadását,
- Nagyobb, városi szintű adatbázisokra való kiterjesztést,
- Több kameranézet integrálását.

A YOLO-alapú megoldás alkalmas valós idejű működésre, így beágyazott rendszerekben (fedélzeti egységek, edge eszközök) is alkalmazható. A modellméret csökkentésével (kisebb YOLO-variáns, kvantizáció) a futási idő tovább javítható. A megoldás integrálható intelligens közlekedési rendszerekbe, ADAS rendszerekbe és városi forgalomfelügyeleti platformokba.

Hivatkozások

- [1] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In *European Conference on Computer Vision (ECCV)*, pages 213–229. Springer, 2020.
- [2] Dan Cireşan, Ueli Meier, Jonathan Masci, and Jürgen Schmidhuber. Traffic sign recognition with multi-column deep neural networks. In *International Joint Conference on Neural Networks (IJCNN)*, pages 333–338. IEEE, 2012.
- [3] Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott Reed, Cheng-Yang Fu, and Alexander C. Berg. Ssd: Single shot multibox detector. In *European Conference on Computer Vision (ECCV)*, pages 21–37. Springer, 2016.

- [4] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 779–788, 2016.
- [5] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster r-cnn: Towards real-time object detection with region proposal networks. *Advances in Neural Information Processing Systems*, 28, 2015.
- [6] Johannes Stallkamp, Marc Schlipsing, Jan Salmen, and Christian Igel. Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition. *Neural Networks*, 32:323–332, 2012.